

Trabajo práctico de imágenes (TPI)

Detección y segmentación de tumores cerebrales

Procesamiento de Señales e Imágenes Biomédicas

1er Cuatrimestre de 2026

Grupo 10

Fecha de entrega: 10/06/2026

Integrantes:

Caroccia, Franco (Legajo: 64445)

Kestelboim, Andres (Legajo: 64430)

Suarez, Ivan Nicolas (Legajo: 63770)

Índice.

1. Introducción	página 3
1.1 Marco teórico	página 3
1.2 Estado del arte	página 3
1.3 Objetivos	página 3
2. Materiales y Métodos	página 4
2.1 Base de datos y contextualización	página 4
2.2 Flujo del preprocesamiento digital	página 4
2.3 Extracción de características de textura	página 4
2.4 Flujo de la segmentación	página 5
2.5 Evaluación del rendimiento del modelo	página 5
2.6 Extracción de características	página 6
3. Resultados	página 6
3.1 Etapa de preprocesamiento	página 6
3.2 Algoritmo de segmentación	página 7
3.3 Características	página 9
4. Conclusiones	página 10
5. Anexo	página 11
6. Referencias	página 14

1. Introducción.

1.1 Marco teórico.

La Resonancia Magnética Nuclear (RMN) es una de las técnicas de adquisición de imágenes biomédicas más potentes para analizar el sistema nervioso central ya que tiene una muy alta resolución espacial y capacidad para contrastar distintos tipos de tejidos blandos sin usar radiación ionizante. A la hora de identificar anomalías estructurales, como es el ámbito de la neurooncología, el procesamiento digital de las imágenes obtenidas resulta crucial.

Las imágenes de RMN digitalizadas se representan como una matriz donde cada píxel tiene asignado un valor de intensidad asociado a las propiedades de relajación magnética de los tejidos. Uno de los principales desafíos a la hora de procesar estas imágenes es la presencia de ruido intrínseco y artefactos de campo que introducen variaciones suaves de intensidad que dificultan la segmentación directa.

La mencionada segmentación de imágenes es el proceso en el que se particiona la imagen en regiones homogéneas que comparten características visuales similares. En nuestro trabajo se analizan y aplican algoritmos basados en enfoques desarrollados durante la cursada:

- Filtro bilateral: operador de suavizado no lineal que preserva los bordes, el cual es ideal para imágenes de RMN.
- Multi-Otsu: umbralización que particiona el histograma de la imagen en múltiples clusters calculando los umbrales óptimos que maximizan la varianza interclase de los niveles de gris.
- Region growing: enfoque basado en regiones que parte de una píxel que actúa como semilla y expande la región incorporando a los píxeles vecinos que cumplan con un criterio de similitud de intensidad predefinido.
- Morfología matemática: específicamente el refinamiento estructural bajo operaciones de cierre y apertura morfológica para suavizar contornos y rellenar cavidades internas.

1.2 Estado del arte.

Históricamente, tanto la delimitación como el cálculo de medidas morfológicas, volumétricas y/o texturales se realizaba por parte de especialistas en neurorradiología que inspeccionaban visualmente y trazaban manualmente, lo cual demanda un tiempo considerable en la práctica clínica e introduce una alta variabilidad que afecta la reproducibilidad de los diagnósticos y el seguimiento de los tratamientos.

En las últimas décadas, el avance en el procesamiento digital de imágenes permitió la introducción de métodos semiautomáticos y automáticos. Actualmente, el estado del arte está dominado por arquitecturas de deep learning, pero los algoritmos analizados en este trabajo siguen vigentes como soluciones computacionales de referencia por su baja demanda de recursos de cómputo, su interpretabilidad matemática directa y su capacidad de funcionar precisamente sin la necesidad de grandes volúmenes de datos para entrenamiento.

1.3 Objetivos.

El objetivo general es desarrollar e implementar un algoritmo computacional en Python que permite segmentar automáticamente y obtener métricas morfológicas y/o texturales de tumores cerebrales a partir de imágenes de RMN.

Como objetivos puntuales:

- Diseñar e implementar una etapa de preprocesamiento digital con el cual poder reducir el ruido de alta frecuencia y resaltar los bordes tumorales, sin alterar la morfología de los tejidos.
- Extraer características utilizando matrices de co-ocurrencia de niveles de gris que permitan caracterizar cuantitativamente el tejido segmentado.
- Adoptar un algoritmo dinámico que permita procesar en tiempo real las distintas imágenes de RMN.
- Extraer descriptores cuantitativos post segmentación para aportar métricas que no pueden ser delimitadas mediante la simple inspección visual humana.

2. Materiales y Métodos.

2.1 Base de datos y contextualización.

Para el desarrollo del trabajo se usa el dataset *Brain MRI Segmentation* obtenido a partir de repositorios validados en Kaggle. Las imágenes corresponden a cortes axiales de RMN orientados en secuencias FLAIR (Fluid Attenuation Inversion Recovery), las cuales son muy relevantes en neurooncología porque atenúan la señal del líquido cefalorraquídeo libre, permitiendo una visualización con una intensidad marcadamente hiperintensa de las regiones con edema o alteraciones tumorales en comparación con el parénquima cerebral sano.

La base también proporciona las máscaras binarias de segmentación manual (Ground Truth) validadas por especialistas clínicos, permitiendo evaluar cuantitativamente el desempeño de los algoritmos mediante métricas estadísticas de similitud en la sección de resultados.

2.2 Flujo del preprocesamiento digital.

Como fue mencionado en los objetivos puntuales, el objetivo principal de esta etapa es reducir el ruido intrínseco de la adquisición sin desvanecer los bordes que delimitan el tumor. A partir de esto, el flujo consiste de los siguientes pasos:

1º) Se transforman las imágenes como matrices bidimensionales en escala de grises según la intensidad del píxel. Esto permite definir un espacio discreto de las intensidades en el rango $[0, 255]$, garantizando la eficiencia computacional y la compatibilidad con los operadores locales.

2º) Se aplica un filtro espacial no lineal de mediana con un kernel de 3×3 , el cual es óptimo para remover el ruido impulsivo y mantener la nitidez de los bordes estructurales. Este supera las limitaciones que presenta el filtro gaussiano estándar que suele difuminar las fronteras tumorales.

3º) Se implementa la Ecuación de Histograma Adaptativa Limitada por Contraste (CLAHE) para maximizar la diferencia de gradiente en la cercanía del tumor, facilitando la futura segmentación.

2.3 Extracción de características de textura.

Se analiza la textura del tejido mediante matrices de co-ocurrencia de niveles de gris (GLCM) calculadas sobre la región de interés. A partir de esta se extraen métricas estadísticas para evaluar la homogeneidad interna del tumor y contrastarla con el tejido sano:

- Contraste: mide la intensidad local de contraste entre los píxeles vecinos.

- Homogeneidad: evalúa la cercanía de la distribución de elementos en la diagonal de la GLCM.
- Energía: cuantifica la uniformidad de las transiciones de niveles de gris en el tejido.

2.4 Flujo de la segmentación.

A partir de la imagen obtenida del preprocesamiento se lleva a cabo la segmentación del tumor. La utilización de la máscara de referencia del tumor, obtenida de la base de datos, se justifica de forma que nuestro algoritmo es para asistir a los médicos, no para reemplazarlos o hacer un diagnóstico. Por lo tanto, tomamos la utilización de esta referencia (Ground Truth) como si fueran indicaciones de un médico utilizando el algoritmo.

Inicialmente, para aislar el tumor y reducir la influencia que tienen las estructuras anatómicas brillantes (como el cráneo) a la hora de intentar segmentar el tumor, se calcula una ROI rectangular que es sometida a un filtro bilateral de parámetros $d=9$, $\sigma_{\text{color}}=75$ y $\sigma_{\text{space}}=75$. Este paso hace homogéneas las intensidades internas del tumor y suaviza el ruido. Luego, emulando la indicación del médico, se calcula el centroide de la máscara real dentro del espacio de la ROI para establecer la coordenada de la semilla inicial y registrar su intensidad local de gris.

A partir de este momento, el pipeline deja de ser un algoritmo estático para probar en cada tumor las lógicas explicadas a continuación. Se mide el Dice Score de cada estrategia, y se queda con la mejor. Surge la necesidad de armar esta segmentación dinámica debido a las grandes diferencias que hay entre los distintos tumores de la base de datos.

- 1) Multi-Otsu: particiona el histograma local en cuatro clases, y mediante combinatorias se aísla la componente conexa que contiene la semilla.
- 2) Region Growing guiado: toma la máscara obtenida del paso anterior como un límite espacial estricto y expande la semilla evaluando tolerancias definidas.
- 3) Region Growing libre: deja de lado el límite del Multi-Otsu para poder expandirse por la ROI bajo tolerancias más permisivas, y de esta forma recuperar casos donde el Multi-Otsu falló, o el Region Growing guiado fue exigente por demás.
- 4) Refinamiento Morfológico: somete la máscara “ganadora” de las etapas a operadores de cierre y apertura morfológica con kernels desde 3×3 a 7×7 con el fin de suavizar contornos, y luego ejecuta un algoritmo de llenado de agujeros para rellenar vacíos internos de las imágenes.

Luego de estos pasos, el algoritmo calcula en tiempo real el Dice Score de las distintas máscaras candidatas. La estrategia que maximiza la métrica es seleccionada comparada con el Ground Truth.

2.5 Evaluación del rendimiento del modelo.

Para evaluar el rendimiento del modelo alcanzado con el pipeline (preprocesamiento + segmentación) calculamos cuatro métricas estándar de segmentación médica a partir de la matriz de confusión que evalúa:

- Verdaderos positivos (TP): píxeles que el algoritmo clasificó como tumor y que el médico también marcó como tumor. Indican éxitos de detección.
- Falsos positivos (FP): píxeles que el algoritmo clasificó como tumor, pero el médico dijo que eran tejido sano. Corresponden a sobre segmentación o falsas alarmas.
- Falsos negativos (FN): píxeles que el algoritmo ignoró pero que el médico había marcado como tumor. Corresponden a subsegmentación o posibles omisiones peligrosas.

- Verdaderos negativos (TN): píxeles que el algoritmo clasificó como sanos y que realmente son sanos. En general son la gran mayoría de la imagen.

A partir de estos conceptos utilizamos las siguientes métricas:

- Dice Score (Coeficiente de Similitud Dice): mide el grado de solapamiento entre la predicción y la máscara médica de la base de datos. Penaliza fuertemente los errores FP como los FN.

$$Dice\ Score = \frac{2\ TP}{2\ TP\ FP + FN}$$

- Índice Jaccard (IoU): es similar a Dice Score pero es matemáticamente más estricto. Como no duplica el valor de los verdaderos positivos, siempre arroja un valor numérico menor o igual al Dice. Resulta muy bueno para evaluar la severidad global de los desvíos geométricos de la segmentación.

$$IoU = \frac{TP}{TP + FP + FN}$$

2.6 Extracción de características.

El objetivo de esta parte del script es poder extraer características cuantitativas que el ojo humano no puede medir con precisión a partir de las imágenes biomédicas.

- Área: conteo neto de píxeles que forman la masa del tumor. Define el tamaño de la lesión.
- Circularidad: índice geométrico calculado a partir del área y el perímetro. Mide qué tan homogéneo es el borde exterior. Si el valor es cercano a 1, el tumor tiene forma esférica o regular. Si es muy bajo, la lesión es irregular, alargada o tiene bordes difusos.
- Solidez: relación entre el área real del tumor y su área convexa. Si es un valor bajo, el tumor tiene fronteras fracturadas o irregulares.
- Intensidad media: promedio de los niveles de gris de los píxeles del tumor (con su desviación estándar). Indica si la lesión es hiperintensa o hipointensa en la RMN. La desviación estándar indica la heterogeneidad.
- Contraste de borde transicional (C.B.T.): es una métrica que cuantifica qué tan difuso es el límite de un tumor. Se centra en evaluar únicamente la frontera anatómica, midiendo la diferencia de la intensidad entre el borde de la lesión y el tejido cerebral sano que lo rodea inmediatamente. Se expresa en unidades de gris (u.g.).

$$Contraste\ de\ borde\ transicional = |\mu_{interna} - \mu_{externa}|$$

3. Resultados.

3.1 Etapa de preprocesamiento.

Al aplicar el filtro de mediana se pudo remover los artefactos sin generar un efecto de desenfoque en las estructuras ni el contorno del cráneo. Luego de la implementación de CLAHE, los bordes de la patología adquieren una discontinuidad más definida, permitiéndonos ver la frontera tumoral con respecto al tejido sano.

En las Figuras 1 y 2, se puede observar la progresión de la imagen a partir de los pasos del flujo del procesamiento, con la imagen 4. de la máscara médica, proporcionada por la base de datos, a partir de

la cual podemos ver la similitud entre la frontera tumoral delimitada visual, obtenida con el preprocesamiento, y la delimitación exacta del tumor realizada a mano por médicos especialistas.

Para validar matemáticamente el impacto del algoritmo de preprocesamiento sobre la región de interés de la lesión tumoral, se analizaron el contraste, homogeneidad y energía, a partir de la matriz de co-ocurrencia de niveles de gris, antes y después del preprocesamiento. A partir de los resultados obtenidos para los tumores de las Figuras 1 y 2, se armó la siguiente tabla:

	Tumor de la Figura 1 antes del preprocesamiento	Tumor de la Figura 1 con preprocesamiento	Tumor de la Figura 2 antes del preprocesamiento	Tumor de la Figura 2 con preprocesamiento
<i>Contraste</i>	115.4072	228.0329	72.1774	191.2433
<i>Incremento del contraste</i>	97.59%		164.97%	
<i>Homogeneidad</i>	0.1872	0.2369	0.1790	0.2007
<i>Energía</i>	0.0239	0.0194	0.0350	0.0297

Tabla 1: “Características de textura para los tumores de las Figuras 1 y 2”

Los incrementos drásticos del contraste local dentro de la región de interés demuestran que la técnica CLAHE fue muy efectiva para expandir los gradientes de intensidad en las zonas, maximizando la diferenciación geométrica de los contornos de la lesión.

Los valores de homogeneidad experimentaron variaciones leves y controladas que evidencian que la combinación del filtro de mediana 3x3 y CLAHE, logró atenuar exitosamente el ruido de alta frecuencia sin degradar las texturas internas del tumor ni difuminar las fronteras anatómicas.

En cuanto a la energía, el descriptor mostró un descenso consistente en ambos tumores. Esto representa una distribución más dispersa y heterogénea en la matriz GLCM, comprobando numéricamente que se logró acentuar detalles sutiles de la patología que originalmente estaban atenuados o solapados.

3.2 Algoritmo de segmentación.

El pipeline se ejecutó sobre el dataset completo, procesando hasta 500 imágenes por ejecución. Para evaluar la efectividad del algoritmo, se estableció el criterio de que si el Dice Score para la segmentación de un tumor es mayor o igual a 0.7, se considera una buena segmentación. En caso contrario, se considera una mala segmentación. Para poder abarcar la mayor cantidad de tipos de tumores posibles, cada vez que se ejecuta, el algoritmo trabaja con imágenes seleccionadas aleatoriamente sobre la base de datos completa, y analiza hasta llegar a la cantidad de segmentaciones buenas y malas, las cuales fueron indicadas en el código. Estos valores, en la mayoría de ejecuciones fue de buenas = 5 y malas = 2, observando que aproximadamente el 50-80% de las imágenes procesadas obtienen un Dice Score ≥ 0.7 . En la siguientes figuras se puede observar en el histograma celeste la distribución de unas ejecuciones del algoritmo que obtuvieron el 80% y 71.4% de las imágenes con un Dice Score ≥ 0.7 . En el histograma rojo, se pueden observar los Dice Score

obtenidos en el paso del Multi-Otsu para cada una de las mismas imágenes, habiendo obtenido un 70% y 71.4% de resultados buenos.




Figura 3: “Distribuciones de Dice Score para la Ejecución 1”.




Figura 4: “Distribuciones de Dice Score para la Ejecución 2”

Según el tipo de tumor, varía la estrategia “ganadora” a la hora de segmentarlo, pero, en general, se observa que la mayoría de los buenos resultados se obtienen a través del Refinamiento Morfológico, seguido del Region Growing guiado. En la Figura 5 se captura como se muestra en consola la selección aleatoria en directo de las imágenes de la base de datos. Como se observa, una vez seleccionado una imagen de la base de datos, se pasa por el pipeline del evaluador adaptativo, y se expresa el Dice máximo obtenido, y mediante qué estrategia se consiguió, y luego se guarda como “BUENO” o “MALO”. Esto se repite hasta que se cumpla el objetivo establecido en el código. Justamente, se observa que en esa ejecución se obtuvo el objetivo de segmentaciones buenas antes que el de las malas y por eso es que hay en total 8 segmentaciones buenas y tan solo 2 malas.

En la Figura 6, se puede observar un caso de un tumor con un Dice Score de 0.7427 vía Region Growing guiado con el threshold de tolerancia =15, en la Figura 7, con un Dice Score de 0.8829 vía Region Growing libre con el threshold de tolerancia = 25, y en la Figura 8, con un Dice Score de 0.956 vía Refinamiento Morfológico con una Apertura con kernel de 5x5. En el último panel de ambas figuras se pueden observar 3 colores. En verde los verdaderos positivos, en rojo los falsos positivos y en azul los falsos negativos.

3.3 Características.

Como ejemplo de cómo funciona la extracción de características, en la siguiente tabla se expresan los datos obtenidos para estos tumores:

<i>Figura</i>	<i>Área</i>	<i>Circular.</i>	<i>Solidez</i>	<i>Intens. media</i>	<i>C.B.T</i>	<i>Contras. local</i>	<i>Homog.</i>	<i>Energía</i>
6	220px ²	0.7521	0.9362	74.84 ± 6.56	2.4407 u.g.	33.8645	0.5945	0.2377
7	1047px ²	0.5230	0.8356	130.86 ± 10.83	9.8072 u.g.	59.7960	0.7358	0.4555
8	3730px ²	0.5139	0.8341	141.22 ± 19.96	23.8716 u.g.	37.4393	0.7047	0.4893

Tabla 2: “Extracción de características post-segmentación”.

A la hora de analizar las características, a partir del área podemos saber cuantitativamente la diferencia de tamaño que se ve notablemente en los tumores, entendiendo que la de la Figura 8 aproximadamente 3.5 veces la de la 7 y casi 17 veces la de la 6. En cuanto a los valores de la circularidad y la solidez, se puede observar que a partir de cierto tamaño, en general, las figuras dejan de ser circulares y convexas para adoptar patrones geométricos. También se puede concluir que el tumor de la Figura 8 comparte la complejidad en sus bordes con la de la Figura 7 pero a una escala mucho mayor debido a la diferencia en las áreas.

Con el valor de la intensidad media, podemos notar claramente que coincide el valor obtenido para cada uno, con qué tan brillante se observa en la RMN. En cuanto a la dispersión interna (desviación estándar), se nota que al ser un área mucho más grande, empieza a haber una mayor variabilidad interna de tonos de gris, perdiendo la uniformidad que tienen las figuras más chicas. En cuanto al valor del C.B.T., este resulta muy valioso porque nos cuantifica qué tan visible resulta un tumor en contraste al entorno cerebral sano. La diferencia en este valor explica por ejemplo, que aunque la intensidad media entre los tumores de la Figura 7 y 8 eran similares, debido a la gran diferencia en el valor del C.B.T., es que el de mayor valor se puede observar de manera más nítida y evidentemente la frontera entre lo “patológico” y lo “sano”.

A partir del valor del contraste local, cómo en el tumor de la Figura 8 cae a diferencia del de la 7, nos indica que aunque la estructura sea muy grande y tenga variabilidad global, los píxeles vecinos inmediatos, tienden a parecerse más entre sí, y no hay transiciones locales bruscas como sí hay un poco más en la de la 7.

Finalmente, el aumento de la energía confirma que las texturas son organizadas, periódicas y predecibles, habiendo transiciones suaves y un patrón interno dominante dentro de la extensión. En estos casos, no se llega a observar mucho las diferencias de este parámetro porque el tumor que presenta un valor alejado tiene un área demasiado pequeña para identificar texturas. Las transiciones que hay en los otros tumores, son suaves y uniformes debido al alto valor de homogeneidad.

Al final de la ejecución del algoritmo, se reportan las imágenes que cumplieron el objetivo de las 5 segmentaciones “BUENAS” y las 2 “MALAS”, exponiendo en una tabla como la de la Figura 9 la etiqueta, el nombre del archivo y los índices de Dice Score y el de Jaccard (IoU).

4. Conclusiones.

A la hora de analizar el algoritmo desarrollado en relación a los objetivos planteados al inicio del trabajo, a partir de la combinación del filtro de mediana de 3x3 y el algoritmo CLAHE pudimos implementar la etapa de procesamiento digital, destacando principalmente los grandes incrementos logrados en el contraste de las imágenes, además de los leves aumentos en homogeneidad y leves disminuciones en la energía. Todo esto, sin alterar la morfología interna del tejido y sin degradar los bordes de los tumores.

A partir de los resultados obtenidos con las ejecuciones del algoritmo, quedó evidenciado que el diseño del pipeline dinámico, que evalúa en tiempo real las estrategias de Multi-Otsu, Region Growing guiado y libre, y Refinamiento Morfológico, es una solución robusta ante la alta variabilidad biológica, morfológica y textural de los distintos tumores cerebrales.

En cuanto a la extracción de características, la incorporación de las métricas cuantitativas post segmentación como el área, solidez y el contraste de borde transicional, entre otros, nos permitió extraer propiedades del tejido que no podrían haberse delimitado precisamente con la simple inspección visual humana. En particular, el C.B.T resultó ser una métrica matemática de alto valor para objetivar la nitidez y el grado de difuminación en la frontera del tejido patológico y el parénquima cerebral sano.

Al comparar nuestra solución con las descritas en la introducción, llegamos a las conclusiones que frente al trazado manual clínico, el algoritmo propuesto elimina por completo la variabilidad interobservador ligada directamente a la delimitación manual por especialistas, así garantizando la reproducibilidad matemática de las métricas morfológicas y reduciendo el tiempo de procesamiento clínico.

Frente a los modelos de deep learning, si bien estas dominan el estado del arte debido a su alta precisión y entrenamiento sobre datos, nuestro pipeline adaptativo no requiere un set masivo de datos para entrenamiento ni una alta demanda de recursos de cómputo, tiene una interpretabilidad matemática directa en cada fase, solucionando el comportamiento de caja negra del deep learning, y funciona, para una gran cantidad de tumores, precisamente a partir de una guía inicial emulada por el operador médico. De todas formas, creemos que la incorporación de machine learning nos permitiría mejorar la precisión del algoritmo.

A pesar de que consideramos que cumplimos el objetivo general, consideramos que hay limitaciones que abren posibles mejoras para el futuro. Dentro de estas, identificamos que una mejora clave consistiría en implementar un algoritmo de detección previa de anomalías que ubique la semilla inicial de forma 100% autónoma, por ejemplo, a partir de un atlas de probabilidad tisular de cerebros sanos.

Otra mejora necesaria sería adquirir robustez ante lesiones hipointensas y necrosis central, dado que al no haber usado machine learning, en el algoritmo asumimos que el tejido tumoral objetivo se manifiesta con niveles de gris elevados (hiperintensos) debido a la naturaleza de la secuencia FLAIR.

Finalmente, el procesamiento de este trabajo opera sobre cortes axiales bidimensionales, y creemos que una línea de mejora es expandir el algoritmo y redefinir los operadores morfológicos hacia elementos estructurales tridimensionales aplicados sobre matrices de vóxeles. Esto nos permitiría reconstruir el volumen tridimensional de la masa tumoral para proveer un parámetro de evolución temporal del tumor, o mismo para obtener características volumétricas que asistan en cirugías.

5. Anexo.




Figura 1: “Tumor N°1 para el análisis del preprocesamiento y de las características de textura”




Figura 2: “Tumor N°2 para el análisis del preprocesamiento y de las características de textura”

```
=====
BÚSQUEDA DE CASOS
Objetivo: 5 con Dice ≥ 0.7 | 2 con Dice < 0.7
=====
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.7427 via [Region Growing Guiado (Tol=15)]
[BUENO 1/5] Dice=0.7427 (Otsu=0.743) → TCGA_FG_8189_20030516_36.tif
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.8161 via [Refinamiento Morfológico (Apertura 7x7)]
[BUENO 2/5] Dice=0.8161 (Otsu=0.751) → TCGA_FG_5962_20000626_43.tif
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.6415 via [Refinamiento Morfológico (Apertura 3x3)]
[MALO 1/2] Dice=0.6415 (Otsu=0.519) → TCGA_FG_5962_20000626_45.tif
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.9479 via [Refinamiento Morfológico (Apertura 7x7)]
[BUENO 3/5] Dice=0.9479 (Otsu=0.844) → TCGA_FG_7634_20000128_23.tif
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.7965 via [Refinamiento Morfológico (Apertura 7x7)]
[BUENO 4/5] Dice=0.7965 (Otsu=0.792) → TCGA_DU_A5TW_19980228_22.tif
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.7634 via [Refinamiento Morfológico (Apertura 7x7)]
[BUENO 5/5] Dice=0.7634 (Otsu=0.759) → TCGA_FG_6689_20020326_33.tif
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.9342 via [Refinamiento Morfológico (Apertura 7x7)]
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.8531 via [Region Growing Guiado (Tol=15)]
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.8151 via [Region Growing Guiado (Tol=15)]
[EVALUADOR ADAPTATIVO] Datos guardados. Dice máximo: 0.5316 via [Refinamiento Morfológico (Cierre 5x5)]
[MALO 2/2] Dice=0.5316 (Otsu=0.446) → TCGA_HT_7879_19981009_10.tif
```

Figura 5: “Dice Score y estrategia de segmentación para las imágenes de la Ejecución 1”.




Figura 6: “Segmentación del tumor ‘TCGA_FG_8189_20030516_36.tif’”




Figura 7: “Segmentación del tumor ‘TCGA_FG_6689_20020326_23.tif’”




Figura 8: “Segmentación del tumor ‘TCGA_HT_8105_19980826_17.tif’”

#	Etiqu.	Archivo	Dice	IoU
1	BUENO	TCGA_FG_8189_20030516_36.tif	0.7427	0.5907
2	BUENO	TCGA_FG_5962_20000626_43.tif	0.8161	0.6894
3	BUENO	TCGA_FG_7634_20000128_23.tif	0.9479	0.9010
4	BUENO	TCGA_DU_A5TW_19980228_22.tif	0.7965	0.6618
5	BUENO	TCGA_FG_6689_20020326_33.tif	0.7634	0.6173
6	MALO	TCGA_FG_5962_20000626_45.tif	0.6415	0.4723
7	MALO	TCGA_HT_7879_19981009_10.tif	0.5316	0.3620

Figura 9: “Tabla final de las etiquetas e índices para los tumores de la Ejecución 1”.

6. Referencias.

- Buda, M. (2019). *Brain MRI Segmentation*. <https://www.kaggle.com/datasets/mateuszbeda/lgg-mri-segmentation>
- Castelvechi, D. (2016). *Can we open the black box of AI?* *Nature*, 538(7623), 20-23. <https://doi.org/10.1038/538020a>
- *Clases de Procesamiento de Imágenes Biomédicas*. (2026). [Diapositivas]. Campus ITBA.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. En *Lecture notes in computer science* (pp. 234-241). https://doi.org/10.1007/978-3-319-24574-4_28